知识图谱概念与技术 · 课程项目期中检查

PC-Mem：把整台电脑的文件变成 Agent 能长期记住的知识库

选题 1 · 帮助 Agent 的全 PC 文件管理记忆系统。用显式的版本链、项目归属、文件间引用与时间线，补上向量检索看不见的那一层结构。

— 期中汇报 · 5 页 / 约 5 分 20 秒　— 2026 年 11 月　— 材料：仓库 personal-agent/ 与 HTML 调研材料

个人文件助手需要补充四类关系

个人电脑的信息结构，集中在向量相似度覆盖不到的关系上。

异构

- 论文、PPT、Word、代码、数据、图片、会议记录
- 10 种格式、4 种模态混在同一棵树里

跨目录

- 同一个项目横跨多个顶层文件夹，最深处到第 6 层
- 目录名只提示结构，查询仍依赖索引

多版本

- 同一材料的 v1 / v2 / final 并存，没有版本管理
- 新旧两版内容高度相似，向量几乎同分

检索需求	普通 RAG 的缺点	需要的显式表示
文档的项目归属	相似度只度量内容，不度量归属；同一主题的文档可以属于不同项目	文档级归属，三级优先级：人工 > 规则 > 模型推断
同一材料的当前版本	两个版本互为近邻，检索层无法判断先后，旧版本会被当证据引用	文档身份 + 修订行 + “当前版本”语义
跨项目的历史复用	只能取回相似段落，取不回工作历史与跨项目脉络	相似 / 引用 / 版本 / 归属四类边 + 时间线浏览

跨来源

同一项目散落在多个目录与格式里，单个目录不是全集。

隐含关系

归属、引用、版本先后多半不写在正文里，向量也读不出来。

动态更新

新文件出现后旧结论可能失效，系统要知道该让哪条证据下线。

> **核心判断** 知识图谱在这里的作用，是让四类关系可查询、可追溯、可随新文件更新。

一个库、一个门面、五路检索

本地文件 → 刷新与解析 → PostgreSQL 底座 → RagService 门面 → 四个入口。

01 本地文件
41 种后缀白名单
PDF / Office / 邮件 / 代码 / OCR

›

02 解析 · 分块
章节路径与表格保持完整
失败按文件记因，不整批失败

›

03 PostgreSQL + pgvector
段落 · 向量 · 全文 · 图 · 版本
一个事务里一起提交

›

04 五路检索
向量 · 关键字 · 图 · 社区 · HyDE
加权 RRF 融合，标注来源层

›

05 带证据的答案
只依据检索到的段落
逐条编号引用，不足则拒答

A · 单库同事务

段落、向量、全文索引、概念图、版本链同在一个 PostgreSQL；一个 passage 和它的图条目一起提交。不引第二个向量库或图数据库——少一个要跑、要备份、要对齐的东西。

B · 一个门面

CLI、REST **/v1**、MCP **/mcp**、Agent hook 全部调 **RagService**；鉴权、权限、引用、错误只有一份实现，四个入口不会各自漂移。

C · 权限先于排序

每条检索在每个检索层里先用 SQL 过滤许可、来源、时间，再排序取前 k；受限请求一律返回空集。社区摘要这类聚合文本同样受同一谓词约束。

D · 本体即约束

domain-personal 声明 12 类实体、11 类关系，每条关系限定源与目标类型；抽取提示词与结果校验共用同一份声明，约束提前到写库之前。

数据模型：一个库装下 10 张表，权限、版本、留痕都落在列上

documents 来源、许可、内容指纹
chunks 检索单元 + 向量 + 全文
document_embeddings 文档级向量均值
document_citations 引用边
kg_entities 实体与证据指针
kg_relationships 带引文的有向边
kg_communities 社区摘要
entity_resolution_audit 合并留痕
projects 项目与人工归属
file_events 刷新审计（无正文）

创新集中在约束层：版本、可见范围与写入留痕

价值来自把文件空间的语义写进 schema、检索与写入路径。

工作	做法（关键约束）	证据
1 版本链与“当前版本”	身份 = 规范路径 + 内容指纹 + 成员键；修订逐条保留，默认只检索 current。旧版本必须在全部读取路径上同时消失（向量、关键字、图、社区、引用、分面、导出、读取）；revert 不被全局去重吞掉。	ADR 0014；版本用例与对抗性负例
2 项目归属三级制	人工 > 规则 > 推断。规则是有序 YAML glob，先匹配先赢；模型只能选已存在的项目，必须给出 ≥ 0.5 的置信度与原文引用，决策写入 receipt。新修订继承人工归属。	ADR 0015；受控语料归属 20/20
3 关系分 store、统一 scoped 读取	相似 / 引用 / 版本 / 归属分别存储，各自带原文证据；文档相似度只对“可见且同版本”的向量求中心，隐藏文档不影响可见文档的相似度分数。一个服务把这些关系暴露给检索与浏览。	ADR 0016；集成 279 条全过
4 抽取以证据为准	规范名后缀与最小词干、关系端点类型、字面出处三重校验：伪造别名、反向 AUTHORED_BY、被合并的无关项目、引错段落的引文，直接丢弃并计数，不进图。	ADR 0018；真实模型对照试验暴露上述四类失败
5 中文检索独立索引	英文索引与查询路径原样保留；新增 jieba 搜索模式 token 列 + GIN 索引，索引与查询用同一分词器。中文走 OR 组合，避免整句被当成一个词元。	ADR 0017；标识符类召回 **0.333 → 1.000**，p95 2.99 → 3.42 ms

配套两项在门面与写入路径：**外发权限默认收敛**——MCP / CLI 默认只放行 public 与 open_commercial，Agent 侧只拿文档 id 与状态；**刷新单写者**——手动、调度、hook、轮询四个渠道共用一个 advisory lock，审计只存状态与计数，路径只存哈希。

系统已跑通，对照实验数据待补

已完成的每一项都能在仓库里复现；两组对照（公开基准与真实文件树）已跑通链路，结果留白待填。

工程交付

- 25 个提交；13 个迁移（6 新增）
- src 3.0 万行，新增 5,300 行（17%）
- 单元 1,735 过 / 0 失败；集成 279 过

抽取与回答（受控 20 例 + 8 对照）

- 实体 120 条：F1 1.00
- 关系 100 条：P 1.00 / R 0.95 / F1 0.974
- 归属 20/20；答案 8/8（有无图相同）

真实样本（Victoria_Subset）

- 137 文件、9 个顶层目录、最深 6 层
- 10 格式、4 模态、11 道标注题
- 41 种后缀覆盖 106 / 137（77%）

公开基准与调研

- MultiHop-RAG：609 篇 / 2,556 题
- 计划 639 题 × 3 条件 = 1,917 次配对
- 8 个候选 benchmark 中，A4 覆盖 0/8

对照实验 A · MultiHop-RAG（n = 639） 待填

条件	答案正确率	证据支撑	配对 p
plain	—	—	—
rag	—	—	—
kg	—	—	—
kg – rag	Δ —	Δ —	—

对照实验 B · Victoria_Subset（11 题） 待填

条件	证据支撑	引用准确	完整性	正确性
RAG	—	—	—	—
KG	—	—	—	—
KG – RAG	Δ —	Δ —	Δ —	Δ —

口径：A 的 plain 无检索、rag 为向量 + 关键字、kg 为五路（含图与社区），三条件逐题配对，p 取 exact McNemar；B 为 RAG（interactive）与 KG（deep），四维 0–2 均分，n = 11，只报差值。

> **读数** 受控语料 F1 1.00 只证明管线；增量 100 文件首刷 2.79 s、无变更 0.47–0.58 s；两组对照的差异尚无数据。

四类评测缺口与五项收尾计划

系统实现完整；对照实验尚未完成。

现存问题

评测缺口 版本链、项目归属、引用边都没有 gold；8 个公开 benchmark 里，文件间引用原生覆盖 **0/8**。

建图成本 一批 10 个 chunk 就要求模型输出约 6,200 token，撞上 8,192 上限后被截断、拆批重试。段落级语料（HotpotQA 约 7.4 万段）任何并发都救不回。

证据强度 F1 1.00 来自单句模板；答案检查是字符串匹配；标签没有独立人工复核；九份审阅模板全部未指派。

解析覆盖 真实用户语料尚未接入；mp3 与 ics 仍未解析；长期记忆只到模板级，没有遗忘策略的实验。

> **判断** 六项基础功能可用、链路可信；图检索与向量检索的差异尚无数据。

到期末的计划

12/01	**自建个人语料** 200–300 个真实文件，标注版本链、项目归属、文件间引用与时间线。
12/06	**MultiHop-RAG 全量**：639 题 × 3 条件，配对检验，写清每层检索的贡献与失效位置。
12/08	**补解析器**：mp3、ics 落地，Victoria 覆盖率从 77% 提到 95% 以上。
12/10	**抽取外参照**：DocRED / CMeIE 映射 8–10 类关系，拿到可比的外部 F1。
12/15	**交付收尾**：技术报告、demo 讲解、组内互评与分工表。

> **期末目标** 用配对实验报告 kg 与 rag 的差异与显著性；零差异、负差异照实写。

附 备查 · 不计时

一页索引：每个结论都能回到证据

课程汇报只讲 5 页；下面这些是提问时用的落点。

代码与文档

系统实现	personal-agent/ · 25 commits · 迁移 0001–0013
架构决策	docs/adr/ 0001–0021（0013–0021 为本项目新增）
全部实测数字	docs/verification.md，逐条标注 receipt
基准与成本	docs/benchmark-catalogue.zh.md
本体	domain-personal/ · 12 类实体、11 类关系

补充调研与素材（HTML）

dataset-benchmark-compare	A1–A8 覆盖矩阵，8 个候选 benchmark 与缺口
victoria-subset-explorer	137 个真实文件的目录树、格式与解析状态
eval-playbook	GPU / API / 笔记本三套评测方案与估时
competitor-research	五个选题的同类项目与“还没人做”的部分

复现入口：三条命令串起环境、建图、基准

```
$ SCI_RAG_DOMAIN_DIR=domain-personal uv run sci-rag doctor
$ uv run sci-rag graph extract --concurrency 8
$ uv run python scripts/run_benchmark_eval.py --dataset ~/data/MultiHopRAG \
  --corpus-dir "$PCMEM_DATA_DIR/multihop" --dry-run
```

> 分工 代码主干、评测运行、调研与文档分别由组内三人完成；**AUTHORS.md** 记录每棵树的产出者，v1.2–v1.8 的交接实现仍待认领署名。

讨论

谢谢，请提问

下一步：把 HippoCamp 的 137 个真实文件标注成 gold，并测出图检索相对“向量 + 关键字”的差异与适用条件。

— PC-Mem · 期中汇报 — 2026 年 11 月